

Naturaleza de la información: agrupación y descripción de datos

Diplomado en Economía Aplicada: Estadística Aplicada

Luis Fernando Escobar — lfernandoescobarc@gmail.com

Business School - UAGRM

Septiembre 2026

Descripción de datos: métodos gráficos

Introducción

¿Cuáles son las ventas proyectadas de un nuevo producto? ¿Seguirá subiendo el precio de las acciones de Google? ¿Quién ganará la Champions League? ¿Qué tan satisfecho quedaste con tu última compra en Starbucks, Hipermaxi o Fidalga?

Introducción

¿Cuáles son las ventas proyectadas de un nuevo producto? ¿Seguirá subiendo el precio de las acciones de Google? ¿Quién ganará la Champions League? ¿Qué tan satisfecho quedaste con tu última compra en Starbucks, Hipermaxi o Fidalga?

Las respuestas a preguntas como éstas provienen de comprender la **estadística**: las fluctuaciones del mercado, las preferencias del consumidor, las tendencias, etc.

Introducción

¿Cuáles son las ventas proyectadas de un nuevo producto? ¿Seguirá subiendo el precio de las acciones de Google? ¿Quién ganará la Champions League? ¿Qué tan satisfecho quedaste con tu última compra en Starbucks, Hipermaxi o Fidalga?

Las respuestas a preguntas como éstas provienen de comprender la **estadística**: las fluctuaciones del mercado, las preferencias del consumidor, las tendencias, etc.

En esta unidad se presentan tablas y gráficos que ayudan a comprender mejor los datos y dan soporte visual a una mejor toma de decisiones: distribuciones de frecuencia, gráficos de barras, gráficos circulares, diagramas de Pareto, gráficos de líneas, histogramas, diagramas de tallo y hoja, y ojivas.

Preguntas clave: ¿qué sugiere el gráfico sobre los datos? ¿qué es lo que vemos?

Toma de decisiones en un entorno incierto

Decisiones en un entorno incierto

Las decisiones frecuentemente se toman con **información limitada**. Los contadores seleccionan una porción de registros para auditar; los inversionistas eligen entre distintas inversiones sin conocer el futuro del mercado; los gerentes usan encuestas para saber si los clientes están satisfechos.

Decisiones en un entorno incierto

Las decisiones frecuentemente se toman con **información limitada**. Los contadores seleccionan una porción de registros para auditar; los inversionistas eligen entre distintas inversiones sin conocer el futuro del mercado; los gerentes usan encuestas para saber si los clientes están satisfechos.

Para cada una de estas situaciones debemos: definir el problema, determinar qué datos se necesitan, recolectarlos, y usar la estadística para resumirlos y tomar decisiones basadas en ellos.

Decisiones en un entorno incierto

Las decisiones frecuentemente se toman con **información limitada**. Los contadores seleccionan una porción de registros para auditar; los inversionistas eligen entre distintas inversiones sin conocer el futuro del mercado; los gerentes usan encuestas para saber si los clientes están satisfechos.

Para cada una de estas situaciones debemos: definir el problema, determinar qué datos se necesitan, recolectarlos, y usar la estadística para resumirlos y tomar decisiones basadas en ellos.

Ejemplos de poblaciones:

- Todos los compradores potenciales de un nuevo producto
- Todas las acciones que cotizan en una bolsa
- Todos los votantes registrados de un país
- Todas las cuentas por cobrar de una corporación

Gráficos para variables categóricas

Gráficos para variables categóricas

Distribución de frecuencias

Tabla que organiza los datos: la columna izquierda son las **clases** (todas las respuestas posibles); la columna derecha, la **frecuencia** de cada clase.

La **distribución de frecuencia relativa** se obtiene dividiendo cada frecuencia entre el total de observaciones y multiplicando por 100%.

Gráficos para variables categóricas

Distribución de frecuencias

Tabla que organiza los datos: la columna izquierda son las **clases** (todas las respuestas posibles); la columna derecha, la **frecuencia** de cada clase.

La **distribución de frecuencia relativa** se obtiene dividiendo cada frecuencia entre el total de observaciones y multiplicando por 100%.

Tablas y gráficos de barras

Si el objetivo es resaltar la **frecuencia** de cada categoría, usamos un **gráfico de barras**: la altura del rectángulo representa la frecuencia. Las barras no necesitan tocarse.

Gráficos para variables categóricas


Índice de Alimentación Saludable (nivel de actividad)

Tabla 1: Nivel de actividad, primera entrevista

Nivel	Participantes	Porcentaje
Sedentario	2,183	48.9
Activo	757	17.0
Muy activo	1,520	34.1
Total	4,460	100.0

Gráficos para variables categóricas

Gráfico de barras — muestra la actividad física del total de personas en la primera entrevista.



Gráficos para variables categóricas

Tablas cruzadas


Una **tabla cruzada** (crosstab o tabla de contingencia) lista el número de observaciones para cada combinación de valores de dos variables categóricas u ordinales. Con f filas y c columnas, se llama tabla $f \times c$.

Tabla 2: Actividad y género

	Hombres	Mujeres	Total
Sedentario	957	1,226	2,183
Activo	340	417	757
Muy activo	842	678	1,520
Total	2,139	2,321	4,460


Gráficos para variables categóricas

Gráfico de componentes (apilado) — muestra el total y la composición por género.



Gráficos para variables categóricas

Gráfico de clúster (lado a lado) — facilita comparar directamente las categorías entre géneros.




Gráficos circulares (pie charts)

Si el objetivo es resaltar la **proporción** de cada categoría respecto al total, usamos un **gráfico circular**: el área de cada segmento es proporcional a su frecuencia.

Tabla 3: Guerra de sistemas Windows
(participación de mercado)

	Enero 2017	Enero 2018
Win7	47.46	41.86
Win10	32.84	42.78
WinXP	5.72	3.36
WinVista	1.20	0.74
Win2003	0.08	0.07
Otros	0.03	0.02

Gráficos circulares (pie charts)



En enero de 2017, Windows 7 (41.86%) y Windows 10 (42.78%) no diferían significativamente; para 2018 Windows 10 ya lideraba.


Diagramas de Pareto

Un **diagrama de Pareto** es un gráfico de barras que muestra la frecuencia de las causas de un defecto, ordenadas de mayor a menor. Separa las "pocas causas vitales" de las "muchas causas triviales" (regla 80-20).

Tabla 4: Errores en la gestión de reclamos de seguros

Categoría	Tipo de error	Frecuencia
1	Códigos de procedimiento y diagnóstico	40
5	Aplicaciones contractuales	37
4	Tarifarios de precios	17
2	Información del proveedor	9
6	Ajustes del proveedor	7
3	Información del paciente	6

Diagramas de Pareto



Los errores 1, 5 y 4 juntos explican casi el **80%** de los errores — los analistas pueden enfocar ahí el esfuerzo de corrección.

Gráficos para series de tiempo

Gráficos para series de tiempo

Una **serie de tiempo** es un conjunto de mediciones, ordenadas en el tiempo, sobre una cantidad de interés — la secuencia importa.

Un **gráfico de líneas** (*time-series plot*) mide el tiempo en el eje horizontal y la cantidad de interés en el eje vertical, uniendo los puntos adyacentes con líneas rectas.

Gráficos para series de tiempo


Una **serie de tiempo** es un conjunto de mediciones, ordenadas en el tiempo, sobre una cantidad de interés — la secuencia importa.

Un **gráfico de líneas** (*time-series plot*) mide el tiempo en el eje horizontal y la cantidad de interés en el eje vertical, uniendo los puntos adyacentes con líneas rectas.

Ejemplos: matrícula universitaria anual, tasas de interés, PIB, precios de cierre de acciones, tipos de cambio, ingresos y gastos gubernamentales, tráfico semanal de un sitio web.

Gráficos para series de tiempo

Ejemplo: PIB de EE. UU. (1929–2009)




Muestra un fuerte **componente de tendencia** ascendente, más marcado en algunos periodos que en otros.

Gráficos para series de tiempo

Ejemplo: Ingresos y gastos del gobierno


Cuando se comparan **dos variables** en el tiempo[†], se grafican ambas series en el mismo eje.



Gráficos para series de tiempo

Ejemplo: Ingresos y gastos del gobierno

Cuando se comparan **dos variables** en el tiempo[†], se grafican ambas series en el mismo eje.



[†]:Nota: graficar como **porcentaje del PIB** en vez de niveles absolutos puede revelar un patrón muy distinto.

Gráficos para variables numéricas

Gráficos para variables numéricas

Distribución de frecuencias para datos numéricos

Regla 1: Número de clases k :

Tamaño de muestra	Nº de clases
Menos de 50	5–7
50 a 100	7–8
101 a 500	8–10
501 a 1,000	10–11
1,001 a 5,000	11–14
Más de 5,000	14–20

Gráficos para variables numéricas

Regla 2: Ancho de clase:

$$w = \frac{\text{Max} - \text{Min}}{\text{Número de clases}} = (\text{siempre redondear hacia arriba})$$

Gráficos para variables numéricas

Regla 2: Ancho de clase:

$$w = \frac{\text{Max} - \text{Min}}{\text{Número de clases}} = (\text{siempre redondear hacia arriba})$$

Regla 3: las clases deben ser **incluyentes y no traslapadas** — cada observación pertenece exactamente a una clase.

Gráficos para variables numéricas

Distribuciones acumuladas

Una **distribución de frecuencia acumulada** contiene el número total de observaciones cuyo valor es menor que el límite superior de cada clase.

Ejemplo: Tiempos de finalización de tarea ($n = 110$)

$$w = (299 - 222)/8 = 10 \text{ (redondeado)}$$

Gráficos para variables numéricas

Tiempo (s)	Frecuencia	%	% acumulado
220-230	5	4.5	4.5
230-240	8	7.3	11.8
240-250	13	11.8	23.6
250-260	22	20.0	43.6
260-270	32	29.1	72.7
270-280	13	11.8	84.5
280-290	10	9.1	93.6
290-300	7	6.4	100.0

Gráficos para variables numéricas

Tiempo (s)	Frecuencia	%	% acumulado
220-230	5	4.5	4.5
230-240	8	7.3	11.8
240-250	13	11.8	23.6
250-260	22	20.0	43.6
260-270	32	29.1	72.7
270-280	13	11.8	84.5
280-290	10	9.1	93.6
290-300	7	6.4	100.0


Conclusión: solo el 72.7% de los empleados completó la tarea dentro de la meta (4.5 min = 270 segundos).

Gráficos para variables numéricas


Histogramas y ojivas

Histograma: barras verticales cuya **altura** es proporcional al número de observaciones en cada intervalo.

Ojiva: línea que conecta los puntos del **porcentaje acumulado** de observaciones bajo el límite superior de cada intervalo.



Gráficos para variables numéricas



Ojiva de los tiempos de finalización — permite leer directamente qué proporción de empleados terminó antes de cualquier tiempo dado.

Gráficos para variables numéricas


Forma de una distribución

Simétrica

Las observaciones están balanceadas alrededor del centro (imágenes espejo).

Asimétrica (sesgada)

- **Sesgo a la derecha** (positivo): cola larga a la derecha — típico en distribuciones de ingreso
- **Sesgo a la izquierda** (negativo): cola larga a la izquierda — Ejemplo, promedios (GPA)



Gráficos para variables numéricas

Diagramas de tallo y hoja

Los datos se agrupan según sus **dígitos principales** (tallo) y los **dígitos finales** (hojas) se listan en orden ascendente.

Ejemplo: Calificaciones de examen final de estadística

Datos: 88, 51, 63, 85, 79, 65, 79, 70, 73, 77

Tallo		Hojas
5		1
6		3 5
7		0 3 7 9 9
8		5 8

Lectura: la calificación más baja fue 51, la más alta 88, y la mayoría de los estudiantes obtuvo calificación 70.

Gráficos para variables numéricas


Diagramas de dispersión

Un **diagrama de dispersión** ubica un punto por cada par de valores de dos variables numéricas — revela:

1. El rango de cada variable
2. El patrón de valores en ese rango
3. Una posible **relación** entre las dos variables
4. La presencia de valores atípicos (*outliers*)

Gráficos para variables numéricas

Ejemplo: Puntaje de matemáticas y GPA universitario



Patrón: tendencia positiva — mayor puntaje de matemáticas tiende a asociarse con mayor GPA, aunque la relación no es perfecta (hay excepciones en ambas direcciones).

Errores en la presentación de datos

Errores en la presentación de datos

Los gráficos mal diseñados pueden **distorsionar la verdad** fácilmente, incluso sin intención deliberada de engañar.

Sesgo cultural: en culturas occidentales se lee de izquierda a derecha — conviene ubicar la información más importante a la derecha del gráfico.

Errores en la presentación de datos

Los gráficos mal diseñados pueden **distorsionar la verdad** fácilmente, incluso sin intención deliberada de engañar.

Sesgo cultural: en culturas occidentales se lee de izquierda a derecha — conviene ubicar la información más importante a la derecha del gráfico.

Histogramas engañosos

Error 1: hacer que la **altura** (y no el **área**) de los rectángulos sea proporcional a la frecuencia, cuando los intervalos tienen **anchos distintos**.

Errores en la presentación de datos

Los gráficos mal diseñados pueden **distorsionar la verdad** fácilmente, incluso sin intención deliberada de engañar.

Sesgo cultural: en culturas occidentales se lee de izquierda a derecha — conviene ubicar la información más importante a la derecha del gráfico.

Histogramas engañosos

Error 1: hacer que la **altura** (y no el **área**) de los rectángulos sea proporcional a la frecuencia, cuando los intervalos tienen **anchos distintos**.

Error 2: usar barras de **ancho igual** cuando los intervalos originales tenían anchos distintos.

Errores en la presentación de datos

Los gráficos mal diseñados pueden **distorsionar la verdad** fácilmente, incluso sin intención deliberada de engañar.

Sesgo cultural: en culturas occidentales se lee de izquierda a derecha — conviene ubicar la información más importante a la derecha del gráfico.

Histogramas engañosos



Error 1: hacer que la **altura** (y no el **área**) de los rectángulos sea proporcional a la frecuencia, cuando los intervalos tienen **anchos distintos**.

Error 2: usar barras de **ancho igual** cuando los intervalos originales tenían anchos distintos.

Regla correcta: el **área** del rectángulo debe ser proporcional a la frecuencia. Si un intervalo es el doble de ancho que los demás, su altura debe ser la mitad de la frecuencia correspondiente.

Errores en la presentación de datos

Ejemplo: Recibos de supermercado (anchos de intervalo desiguales)



Errores en la presentación de datos



El gráfico de la izquierda **exagera** visualmente la proporción de recibos en la última clase (más ancha). El de la derecha corrige el área.

Regla de oro: nunca construir un histograma con anchos de clase distintos representados incorrectamente — asociamos visualmente el *área* con el tamaño.

Gráficos de series de tiempo engañosos

Elegir una escala particular en el eje vertical puede crear una impresión de **estabilidad** o de **fluctuación sustancial**, sin cambiar los datos subyacentes.

Ejemplo: Puntajes de matemáticas 1989–2009



Los mismos datos — una escala estrecha sugiere gran volatilidad; una escala amplia sugiere estabilidad. **No existe una escala "correcta" única** — siempre hay que examinar los valores del eje, no solo la forma del gráfico.

Resumen del capítulo

Resumen

1. Las variables se clasifican como **categóricas o numéricas** (discretas/continuas), y por **nivel de medición**: nominal, ordinal, de intervalo, de razón.
2. Variables **categóricas**: distribuciones de frecuencia, gráficos de barras, tablas cruzadas, gráficos circulares, diagramas de Pareto.
3. Datos de **series de tiempo**: gráficos de líneas que revelan tendencia.
4. Variables **numéricas**: distribuciones de frecuencia con reglas para el número y ancho de clases, histogramas, ojivas, forma de la distribución (simetría/sesgo), diagramas de tallo y hoja, diagramas de dispersión.
5. **Cuidado con los gráficos engañosos**: anchos de barra inconsistentes en histogramas y elección arbitraria de escala en gráficos de series de tiempo pueden distorsionar la interpretación sin alterar los datos.